



«SONABA COMO SIRI DESPUÉS DE UN CAFÉ»: EL OÍDO HUMANO COMO DETECTOR DE *DEEPPAKES* DE VOZ

Eugenia San Segundo y Aurora López-Jareño
Consejo Superior de Investigaciones Científicas

- 1. PROBLEMA Y OBJETIVOS:** La síntesis de voz ha alcanzado en los últimos años un nivel de realismo que hace difícil distinguir entre voces humanas y artificiales. Esta capacidad tecnológica, sin embargo, conlleva riesgos significativos: los *deepfakes* de audio pueden facilitar la suplantación de identidad, la propagación de noticias falsas y ocasionar daños psicológicos, financieros y sociales. Diversos estudios evidencian la limitada capacidad humana para detectar estas voces sintéticas. Mai et al. (2023) reportaron un 73% de acierto con una alta tasa de falsos positivos (31,3%), mientras que Groh et al. (2024) hallaron un 72% de precisión y un 14% de falsos positivos, aunque en condiciones experimentales favorables. En situaciones más realistas, la vulnerabilidad aumenta: los participantes fueron engañados por voces artificiales en el 87% de los casos. Pese a ello, pocos estudios han explorado las razones detrás de las decisiones perceptivas de los oyentes, lo que motiva el presente trabajo.
- 2. FUNDAMENTACIÓN TEÓRICA Y METODOLÓGICA:** El objetivo de esta investigación fue analizar cualitativamente las respuestas de 54 participantes (28 hispanohablantes y 26 japoneses) a la pregunta: “¿En qué te has fijado para decidir si la voz que acabas de escuchar es real o es artificial?”. Para ello, se diseñó un experimento perceptivo en PsychoPy (distribuido en línea mediante Pavlovía) en el que cada participante escuchó 80 estímulos, mitad naturales y mitad generados con el software de clonación de voz ElevenLabs, y clasificó cada uno como “natural” o “artificial”, justificando a continuación su elección. Se recopilaron 1760 respuestas abiertas, que fueron categorizadas manualmente en tres grupos: (1) rasgos segmentales, (2) aspectos suprasegmentales y (3) características lingüísticas de alto nivel o extralingüísticas.
- 3. RESULTADOS Y CONCLUSIONES:** Nuestro análisis cualitativo ofrece información valiosa sobre las estrategias que emplean los seres humanos al distinguir entre audio auténtico y sintético. Si bien existen claves perceptivas comunes entre los oyentes de japonés y español, también encontramos diferencias notables en la forma en que conceptualizan la “humanidad” del habla. En términos generales, ambos grupos se basaron principalmente en rasgos suprasegmentales y en características de nivel superior o no lingüísticas. Entonación, ritmo, fluidez, pausas, velocidad, respiración y risa fueron los indicadores más citados, por encima de los rasgos segmentales. Estos resultados coinciden, en parte, con trabajos previos que destacan el valor de la prosodia y de los fenómenos propios del habla espontánea, como las disfluencias, para distinguir voces humanas de voces sintéticas o clonadas.

REFERENCIAS

Groh, M., Sankaranarayanan, A., Singh, N., Kim, D. Y., Lippman, A., & Picard, R. (2024). Human detection of political speech deepfakes across transcripts, audio, and video. *Nature communications*, 15(1), 7629.

Mai, K. T., Bray, S., Davies, T., & Griffin, L. D. (2023). Warning: Humans cannot reliably detect speech deepfakes. *PLOS ONE*, 18(8), e0289567.